GLO-2005 Modèles et langages des bases de données pour ingénieurs

Introduction

Survol

- Pourquoi étudier les bases de données?
- Schémas, modèles, langages, et utilisateurs de BD
- Livres
  - Ramakrishnan & Gehrke : chapitre 1
  - Connolly & Begg : chapitre 1

Mise en situation

- Royaume-Uni, septembre 2020
  - Le système Test-and-Trace du gouvernement est en place depuis juin
  - Permet de documenter les individus qui testent positifs à la covid-19 et de retracer les personnes avec qui ils ont été en contact
  - « *World-beating system* » selon le PM Boris Johnson
  - Puis, 15 841 cas positifs ont été perdus dans la dernière semaine de septembre
    - Les personnes proches n'ont pas été contactées, et ont propagé la maladie à leur insu

POPULAR MECHANICS

The U.K. Lost 16,000 COVID Cases Because It Doesn't Understand Microsoft Excel

Someone over there slept through Accounting 101.

The Guardian

Covid: how Excel may have caused loss of 16,000 test results in England

Public Health England data error blamed on limitations of Microsoft spreadsheet

BBC NEWS

Home | US Election | Coronavirus | Video | World | US & Canada | UK | Business | Tech | Science |

Tech

Excel: Why using Microsoft's tool caused Covid-19 results to be lost

METRO NEWS

NEWS SPORT ENTERTAINMENT SOAPS LIFESTYLE PLATFORM VID

CORONAVIRUS UK US WORLD WEIRD TECH

How were 16,000 Test and Trace coronavirus cases lost on Microsoft Excel?

NEWS18 BUZZ

UK Lost Data on 16,000 Covid-19 Cases Because 'Excel Didn't Have Enough Columns'

INDIA TODAY

UK misplaces data on nearly 16,000 coronavirus cases as 'excel didn't have enough columns'

THE LONDON ECONOMIC

Home > Politics

Shock and despair follow revelations that 'world-beating' Test and Trace system is being run on Excel

"Next they'll tell us it's run on Windows 95 and they manually back it up on floppy disks each night."

Mise en situation

- Les patients étaient documentés dans une vieille version de Excel
  - Limite de 65 000 rangées
  - Chaque test génère plus de 40 rangées
  - Limite de 1 400 patients par feuille
  - Les patients supplémentaires n'ont jamais été enregistrés et l'exception générée par Excel n'était pas traitée
- Comment aurait-on pu éviter ce problème?
  - C'est le sujet de ce cours!

Introduction

- Le gouvernement britannique n'est pas le seul à faire face à une explosion de données
- On vit dans un monde de données
  - Données personnelles, données institutionnelles, données d'utilisation, données scientifiques, données ludiques, etc.
- La gestion efficace de ces données est un problème critique
  - Mais pas nouveau: les premières BD datent des années 60s
  - A mené au modèle de bases de données relationnelles et au langage SQL qui sont le standard aujourd'hui

SGBDR

- Base de donnée relationnelle est:
  - Une collection structurée de données variées
    - BD, relation, tuple, attribut, valeur
    - Valeur peut être n'importe quoi
  - Une représentation du monde réel
    - Les entités (ex.: étudiants, cours, profs)
    - Les relations entre les entités (ex.: Bob suit le cours GLO-2005 enseigné par Dr. Khoury)
- Un système de gestion de bases de données relationnelles (SGBDR, *relational database management system, RDBMS*) est un logiciel permettant d'emmagasiner ces données et de les retrouver par des requêtes

SGBDR

- Il existe des douzaines de SGBDR
  - Offrent tous les mêmes fonctionnalités de base
  - Diffèrent sur les fonctionnalités disponibles, l'interface graphique, les limites techniques, les licences d'utilisations, les coûts, la taille de la communauté d'utilisateurs, etc.
  - Les plus populaires incluent : Microsoft SQL Server, Microsoft Access, Oracle DB, MySQL, PostgreSQL, SQLite, MariaDB

Structure d'un SGBDR (et notre cours)

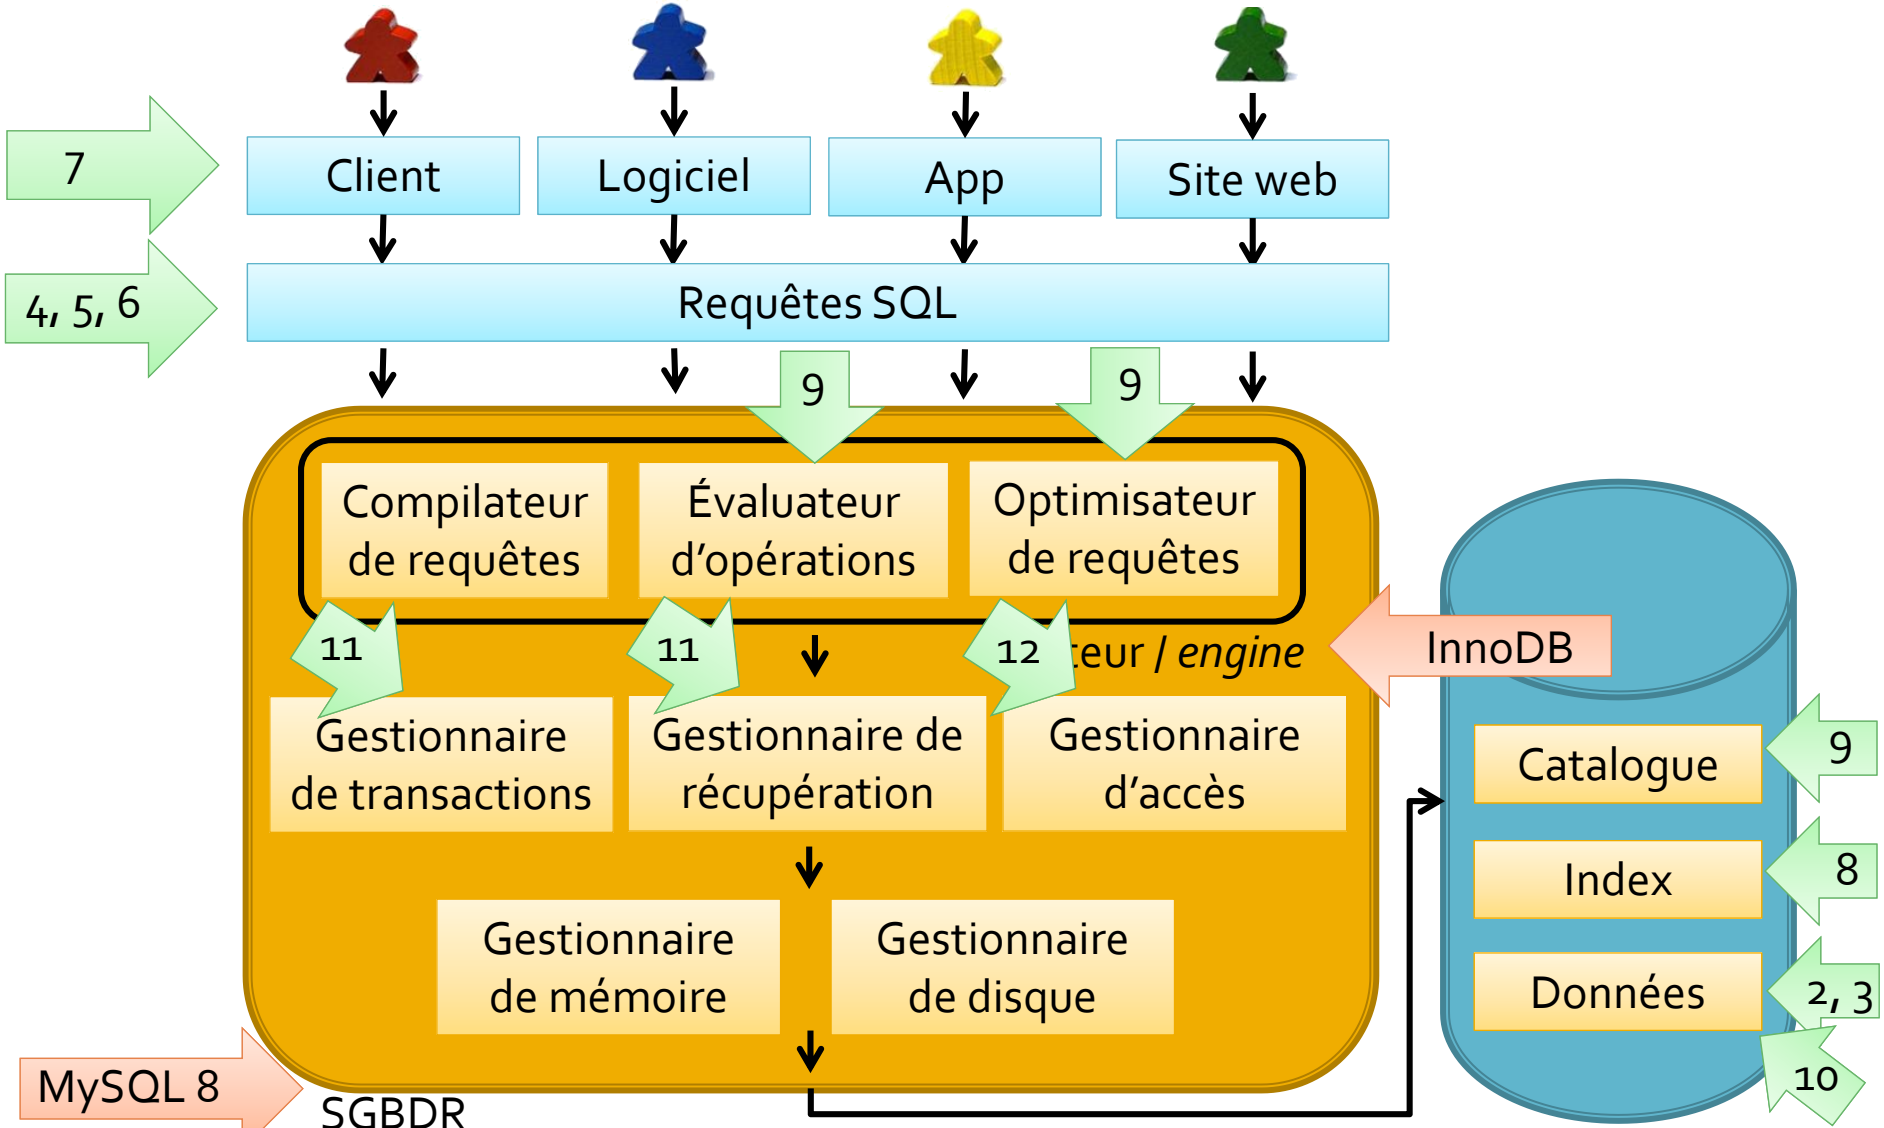

Avantages des SGBDR

- Tout bon ordinateur vient avec un système de gestion de fichiers
- Pourquoi ne pas simplement l'utiliser?
  - Garder nos données dans des fichiers

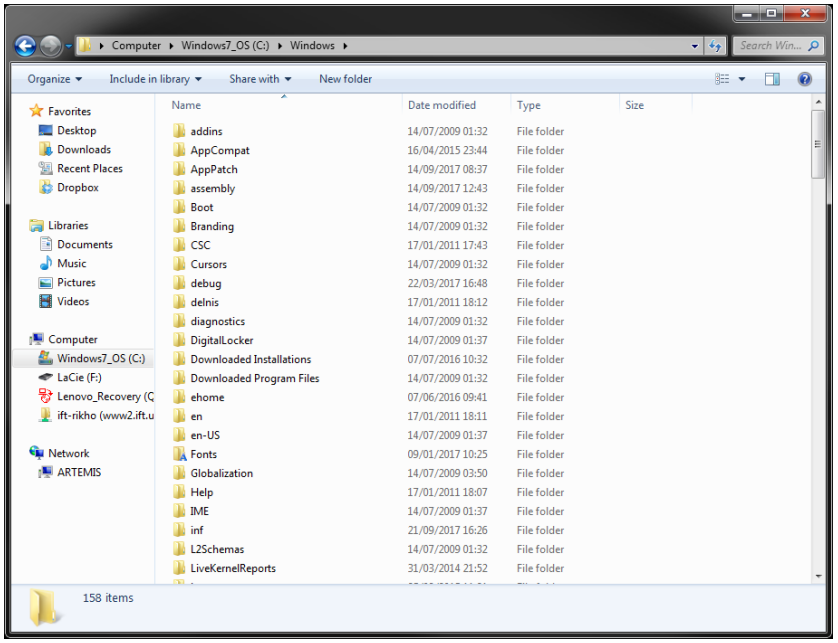

- Un SGBDR permet de régler ou d'éviter plusieurs problèmes de gestion des données

Avantages des SGBDR

- Redondance et incohérence des données
  - Si les données sont divisées en plusieurs fichiers, des informations peuvent être dupliquées (redondance)
  - Si les informations dupliquées ne sont pas toutes mise à jour simultanément, on ne sait plus quelle information est correct (incohérence)
  - SGBDR permet de centraliser les données et d'éliminer la redondance et l'incohérence

Avantages des SGBDR

- Persistance polyglotte
  - Des données en plusieurs fichiers peuvent être emmagasinées dans plusieurs formats différents (polyglotte)
  - Il faudra un logiciel spécialisé à chaque format de données
  - Développer des applications haut-niveau nécessite de connaitre chaque logiciel spécialisé ou chaque format
  - SGBDR permet de conserver toutes les données en un format uniforme dans un seul logiciel, et de développer des applications de haut-niveau dans un langage standard

Avantages des SGBDR

- Dépendance entre les données et les applications
  - Un logiciel spécialisé va imposer sa propre structure sur les données et son propre format d'emmagasinage des données
  - Données inutilisables par un autre logiciel
  - Changements au logiciel peuvent perdre des données
  - SGBDR garantit une indépendance entre les données et les applications

Avantages des SGBDR

- Absence de gestion des changements
  - Un système de gestion de fichiers vise à préserver les fichiers (archivage, récupération en cas d'échec)
  - Ne vise pas à protéger les changements faits aux fichiers
    - Sauf en enregistrant la version finale au disque
    - En cas d'échec durant un changement, un fichier peut être partiellement changé de manière imprévisible, ou peut être corrompu et perdu
  - SGBDR a des mécanismes axés sur la protection des changements (transactions)
    - Atomicité assure qu'un changement est réalisé au complet ou pas du tout
    - Journalisation (*journaling*) conserve des métadonnées sur les changements pour restauration en cas d'échec du système

Avantages des SGBDR

- Accès concurrent limité ou non-sécuritaire
  - Plusieurs systèmes de gestion de fichiers vont verrouiller un fichier utilisé par un utilisateur/logiciel (absence d'accès concurrent)
  - Alternativement, si un fichier peut être édité par plusieurs utilisateurs simultanément, la dernière version enregistrée écrase les autres (accès concurrent non-sécuritaire)
  - SGBDR permet à plusieurs utilisateurs d'accéder et d'éditer les données simultanément de manière sécuritaire

Utilisateurs de BD

- Plusieurs types d'utilisateurs de BD
- Utilisateur occasionnel
  - Utilise une application ou un site web qui accède aux données à travers une interface graphique
  - N'est pas conscient de la BD
  - Souvent n'a pas de formation technique
- Analyste
  - Analyse et forage de données pour découvrir des patrons ou des tendances
  - Conscient de la BD et des données, utilise des outils qui les exploitent directement
  - Peut être formé dans un langage de requêtes mais pas en développement de BD ou d'applications

Utilisateurs de BD

- Développeur
  - Développe des logiciels qui accèdent et modifient la BD
  - Bonne formation technique en programmation et en BD, familier avec un langage de requêtes
- Administrateur (DBA)
  - Conçoit, crée, développe et maintient la BD
  - Excellente formation technique en modélisation, en développement de BD, et en programmation
  - Bonne connaissance du domaine d'application et des besoins & ressources informatiques de l'entreprise
  - Objectif de ce cours!

Schéma des données

- Les différents utilisateurs comprennent les données différemment
  - Différents besoins
  - Différents droits d'accès
  - Différents niveaux techniques
- Il existe différentes conceptualisations des données
  - Différents niveaux d'abstraction des données correspondant à la vision des différents utilisateurs
  - Schémas des données

Schéma des données

- Schéma physique
  - Décrit les données telles qu'elles sont emmagasinées sur le disque
  - Secteurs et index
- Schéma conceptuel
  - Décrit la structure logique des données
  - Donne une dimension sémantique aux données
- Schéma externe
  - Vue des données montrée aux utilisateurs
  - Peut être adapté aux besoins spécifiques de chaque application

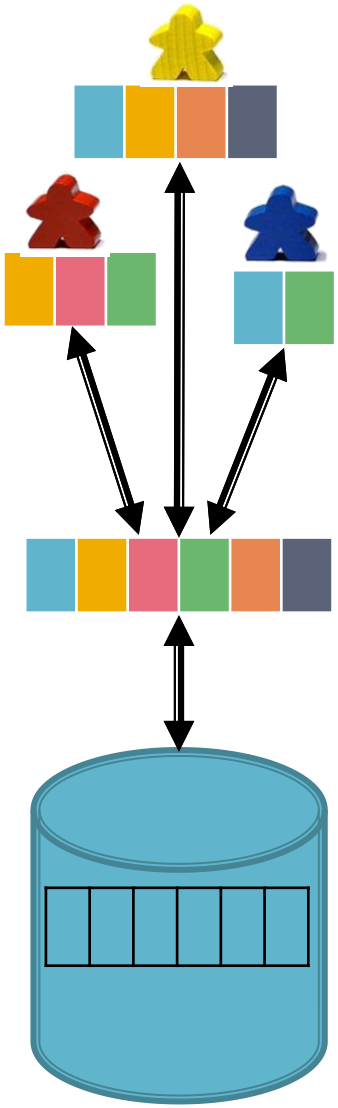

Schéma des données

- Schéma conceptuel
  - Décrit tous les concepts pertinents du domaine
  - Invariant dans le temps
  - Exclut les notions d'organisation physique, d'accès aux données, ou d'utilisation des données

Étudiants

Nom	Adresse	Sexe	Âge	Courriel	Note cours 1	Note cours 2	Moyenne de programme

Schéma des données

- Schéma physique
  - Décrit comment l'information du schéma conceptuel est organisée physiquement

Étudiants

Nom	Adresse	Sexe	Âge	Courriel	Note cours 1	Note cours 2	Moyenne de programme

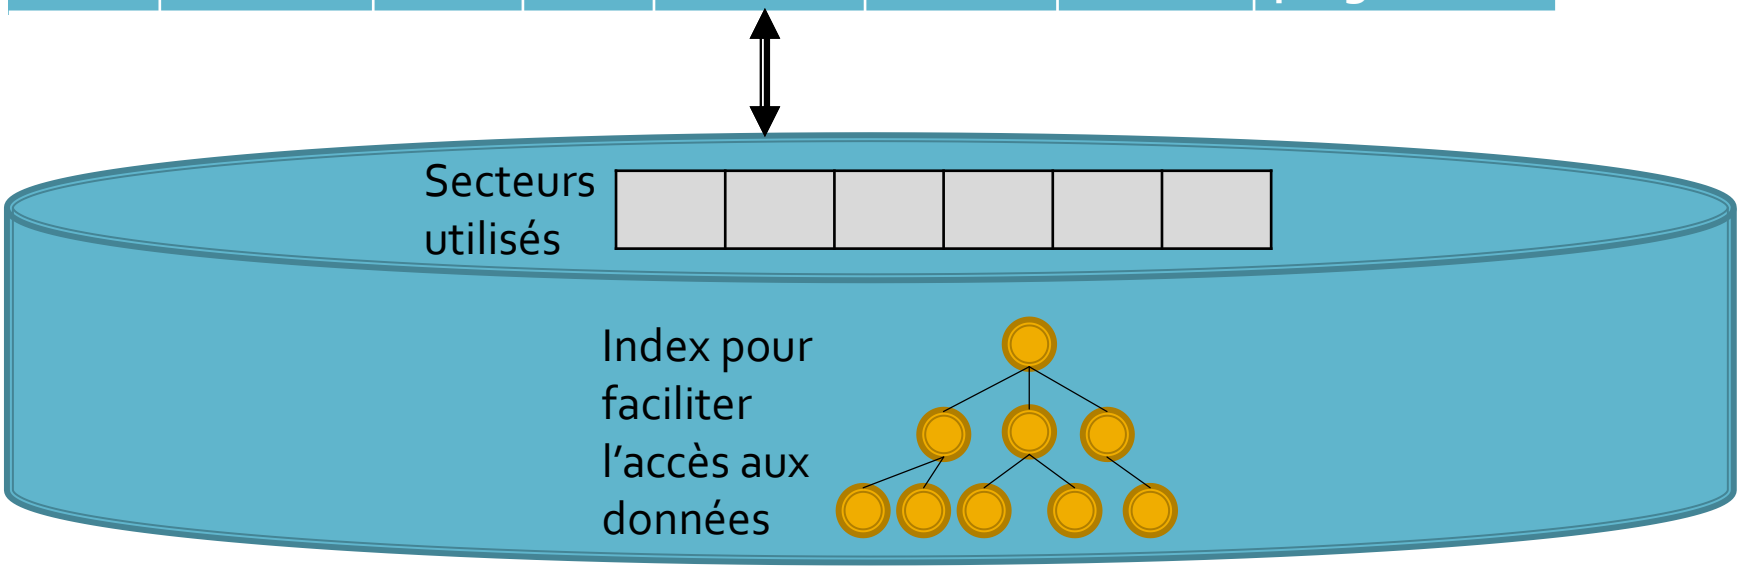

Schéma des données

- Schéma externe
  - Décrit la sous-partie du schéma conceptuel qui sera visible à un groupe d'utilisateurs

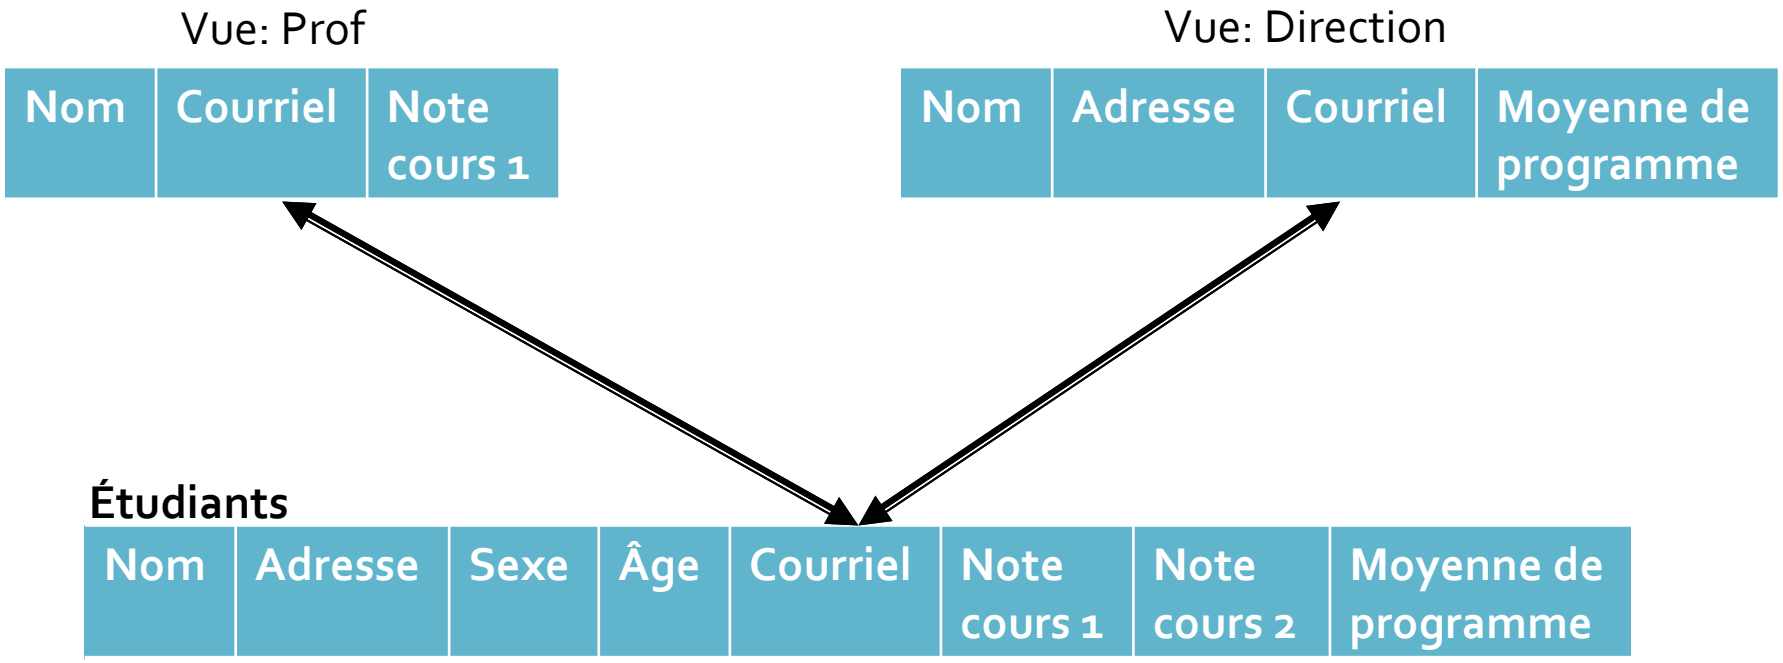

Modèles de données

- Un modèle de données est une collection de concepts qui décrivent
  - Les données
  - Les relations entre les données
  - La sémantique des données
  - Les contraintes sur les données

Modèles de données

- Deux modèles de données dans ce cours
  - Modèle entité-relation
  - Modèle relationnel
- Autres modèles utilisés en BD
  - Modèle orienté-objet
  - Modèle réseau
  - Modèle hiérarchique
  - Modèle entité-attribut-valeur
  - Etc.

Modèles de données

Étudiants

Nom	Adresse	Sexe	Âge	Courriel	Note cours 1	Note cours 2	Moyenne de programme

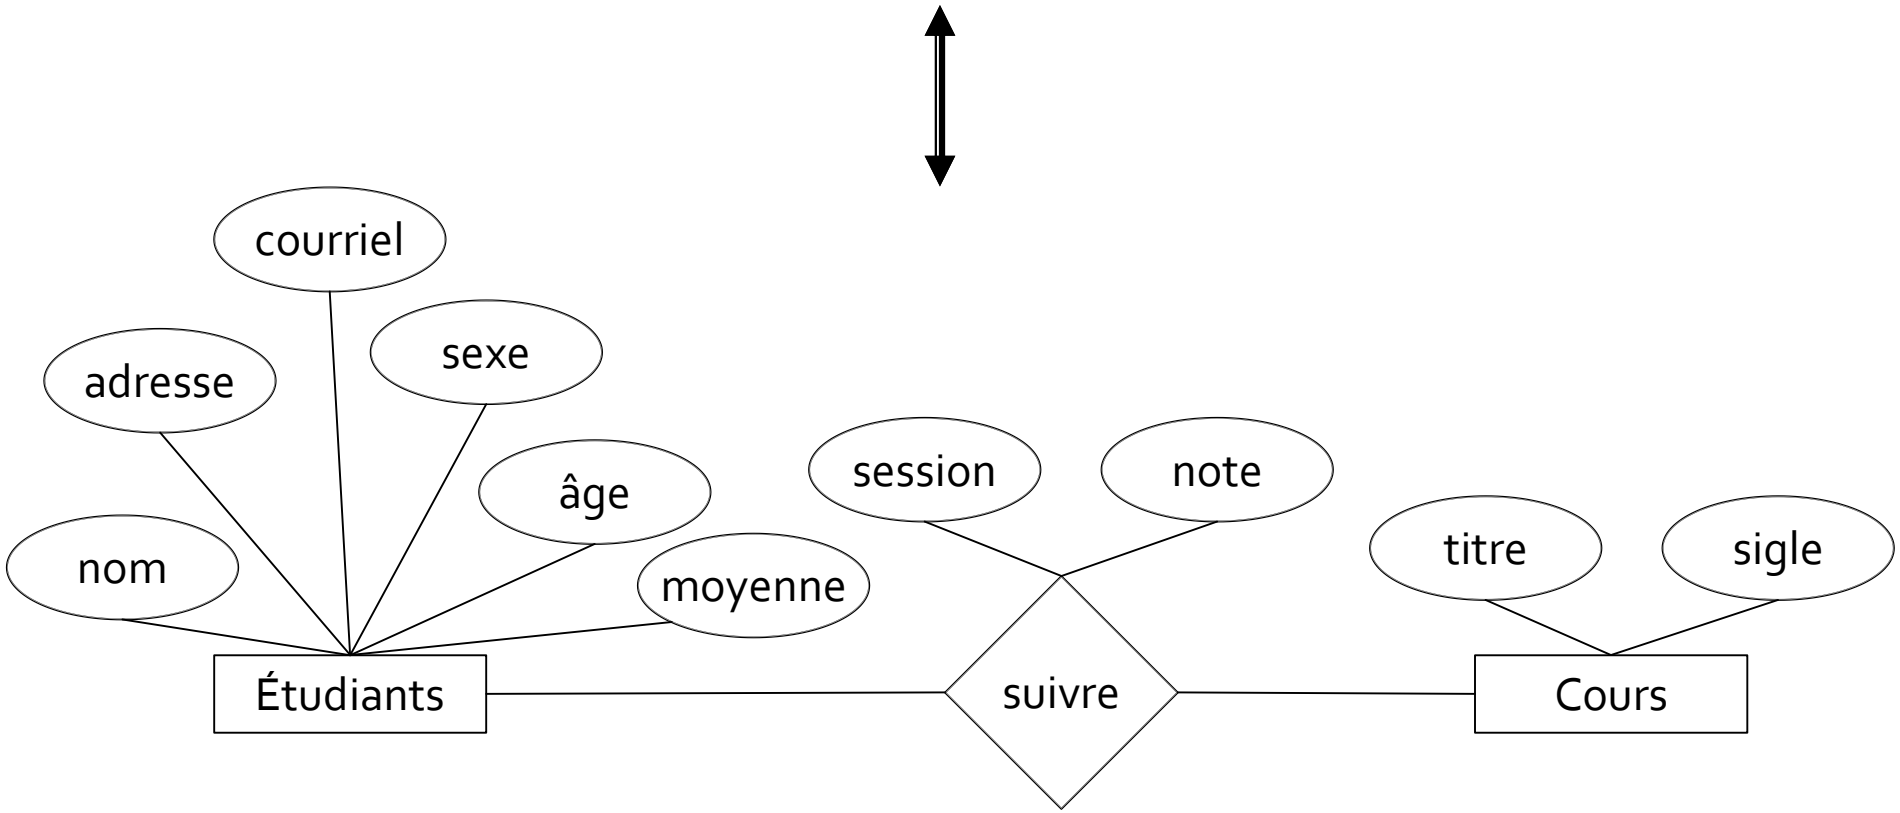

Langages de BD

- Langage de définition des données
  - Langage permettant de définir le schéma conceptuel de la BD
  - Compilateur du langage génère les tableaux de la base de données
- Langage de manipulation des données
  - Langage permettant d'accéder aux données de la BD, de les modifier, et de faire des requêtes
  - Deux familles
    - Langage procédural: spécifie quelle donnée est requise et comment l'obtenir dans la BD
    - Langage non-procédural: spécifie quelle donnée est requise mais pas comment l'obtenir dans la BD

Langages de BD

- SQL (*Structured Query Language*)
  - Langage de définition et de manipulation des données le plus commun
  - Non-procédural: un optimisateur de requêtes dans le SGBDR détermine comment obtenir les données
  - Permet de définir la BD et les contraintes
  - Permet à nos applications d'accéder aux données
  - Exemple: on veut les étudiants de moins de 21 ans avec une moyenne de plus de 4.0
    - ```
      SELECT nom
      FROM Étudiants
      WHERE moyenne > 4.0 AND âge < 21;
      ```
      ```

Création de BD

1. Analyse
   - Parler aux clients et utilisateurs
   - Comprendre le domaine d'application
2. Modélisation
   - Découvrir les entités, leurs attributs, les relations entre elles, les contraintes auxquelles elles sont soumises
3. Schématisation
   - Structurer les données, définir les index et vues, optimiser le système
4. Implémentation
   - Écrire le code SQL

Cours vs. ChatGPT

- ChatGPT peut générer le code SQL en réponse à nos besoins!
- Pourquoi donner un cours de BD à l'ère des IA génératives?

RI Comment faire le code SQL pour obtenir une liste d'étudiants?

Pour obtenir une liste d'étudiants à partir d'une base de données, vous devez utiliser une requête SQL. La structure de cette requête dépendra de la façon dont vos données sont organisées dans la base de données. Voici un exemple de code SQL générique pour obtenir une liste d'étudiants :

sql Copy code

```sql
SELECT * FROM etudiants;
```

Cela récupérera toutes les colonnes de la table "etudiants". Si vous souhaitez spécifier des colonnes spécifiques, vous pouvez les mentionner séparément dans la requête :

sql Copy code

```sql
SELECT nom, prenom, age FROM etudiants;
```

Cela ne retournera que les colonnes "nom", "prenom" et "age" de la table "etudiants". Assurez-vous de remplacer "etudiants" par le nom réel de votre table contenant les informations des étudiants.

Si vous avez des critères spécifiques pour filtrer les étudiants (par exemple, obtenir uniquement les étudiants d'une certaine classe ou d'un certain programme), vous pouvez ajouter une clause WHERE à votre requête :

sql Copy code

```sql
SELECT nom, prenom, age FROM etudiants WHERE programme = 'Informatique';
```

Cela ne retournera que les étudiants dont le programme est "Informatique". Vous pouvez personnaliser cette condition en fonction de vos besoins.

N'oubliez pas de vous connecter à votre base de données et d'exécuter cette requête à l'aide d'un outil de gestion de bases de données tel que MySQL, PostgreSQL, Oracle, etc.

Cours vs. ChatGPT

- Les IA génératives sont nouvelles
- Mais la solution de consulter n'est pas nouvelle

RI Comment faire le code SQL pour obtenir une liste d'étudiants?

Pour obtenir une liste d'étudiants à partir d'une base de données, vous devez utiliser une requête SQL. La structure de cette requête dépendra de la façon dont vos données sont organisées dans la base de données. Voici un exemple de code SQL générique pour obtenir une liste d'étudiants :

sql Copy code

```sql
SELECT * FROM etudiants;
```

Google

Comment faire le code SQL pour obtenir une liste d'étudiants?

stackoverflow

Developpez.com
Club des professionnels de l'IT

w3schools.com

Comment faire le code SQL pour obtenir une liste d'étudiants?

Database Management Systems

Comment faire le code SQL pour obtenir une liste d'étudiants?

SELECT * FROM Étudiants;

Cours vs. ChatGPT

- Les IA génératives peuvent vous dire quel est le code SQL qui répond à votre besoin
- Les IA génératives ne peuvent pas vous dire :
  - Quels sont vos besoins (ou ceux du client)
  - Comment résoudre des bogues dans le code
  - Comment intégrer le code dans un système
  - Est-ce que le code est optimal?
  - Est-ce que le code est robuste?
  - Est-ce que le code est sécure?
  - Est-ce que le code respecte les bonnes pratiques et les législations en place?
  - Est-ce que le code soulève des questions éthiques?

Cours vs. ChatGPT

- L'objectif du cours n'est pas d'entraîner des générateurs de code humains pour rivaliser avec des IA génératives
- L'objectif du cours est de former des ingénieurs qui *comprennent* tous les aspects des SGBDR

Résumé

- Avantages des SGBDR pour la gestion sécuritaire et uniforme des données
- Utilisateurs des BDs
- Schéma physique, conceptuel, et externe des données
- Modèle des données et langage SQL

Exercices

- Ramakrishnan & Gehrke
  - 1.1, 1.4
- Connolly & Begg
  - 1.2, 1.4, 1.6